데이터사이언스 1조

바나나를 새로 배운 ResNet-50도 패치에 속을까?

적대적 패치 전이성 검증 · 모델 A·B·C

02

지난 결과



팀이 학습시킨 바나나 패치

ResNet-50가 banana라고 답한 비율

98.6%

처음 보는 사진 1,000장에 패치를 붙였을 때

구조가 다른 모델에서는

VGG-16	MobileNet-V2	DenseNet-121
0%	5.1%	3.8%

그렇다면, 같은 ResNet-50을 바탕으로 바나나를 새로 배운 모델도 속을까?

03

바나나를 새로 배운 모델

ResNet-50
ImageNet 1,000종으로 이미 학습된 모델

→

마지막 층 교체
출력 1,000개 → 11개

→

우리 사진으로 학습
Imagenette 10종 + 바나나

전이학습: 이미 배운 '사진 읽는 법'은 그대로 쓰고, 마지막 '답 고르는 칸'만 새로 만든다

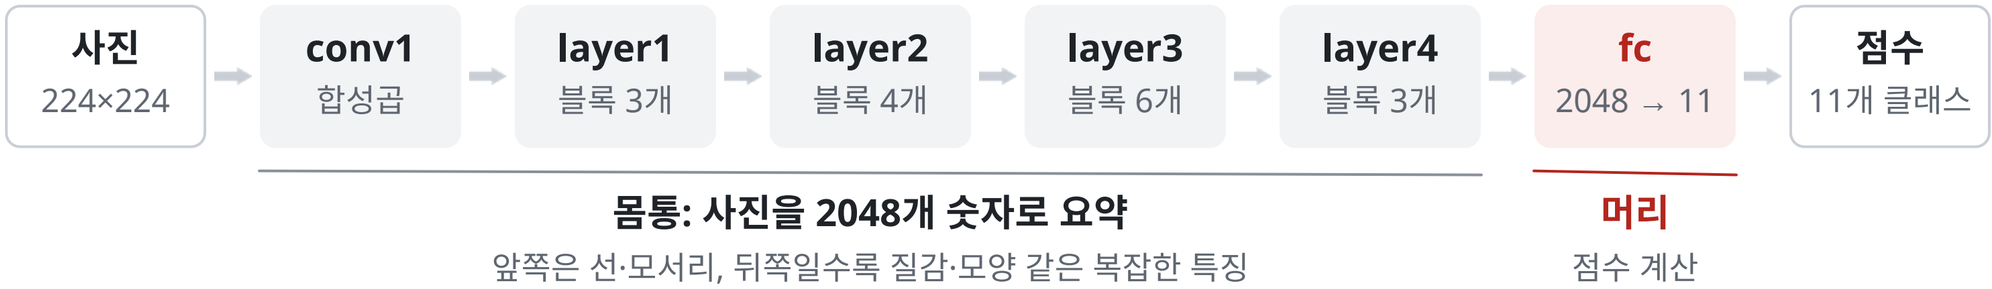
데이터 학습 10,419장 · 검증 4,315장

바나나 사진: Kaggle · Roboflow Universe "Banana Ripeness Classification" (CC BY 4.0), 원본 1장당 1장만 사용해 학습 950장 · 검증 390장

04

ResNet-50 구조와 모델 A·B·C

50층 CNN · 블록마다 입력을 그대로 더해 주는 지름길(skip connection)이 있어 깊어도 학습이 잘 된다



모델 A
fc만

고정 — 학습

모델 B
fc + layer4

고정 — 학습

모델 C
전체

전부 학습 (모델값에서 조금씩 수정)

세 모델 모두 모델 값에서 출발 · 고정 = 학습하는 동안 값을 바꾸지 않음

05

모델 정상 작동 확인



새로 가져온 실제 바나나 사진

이 사진을 '바나나'로 본 확률

모델 A	모델 B	모델 C
98.3%	**100%**	**100%**

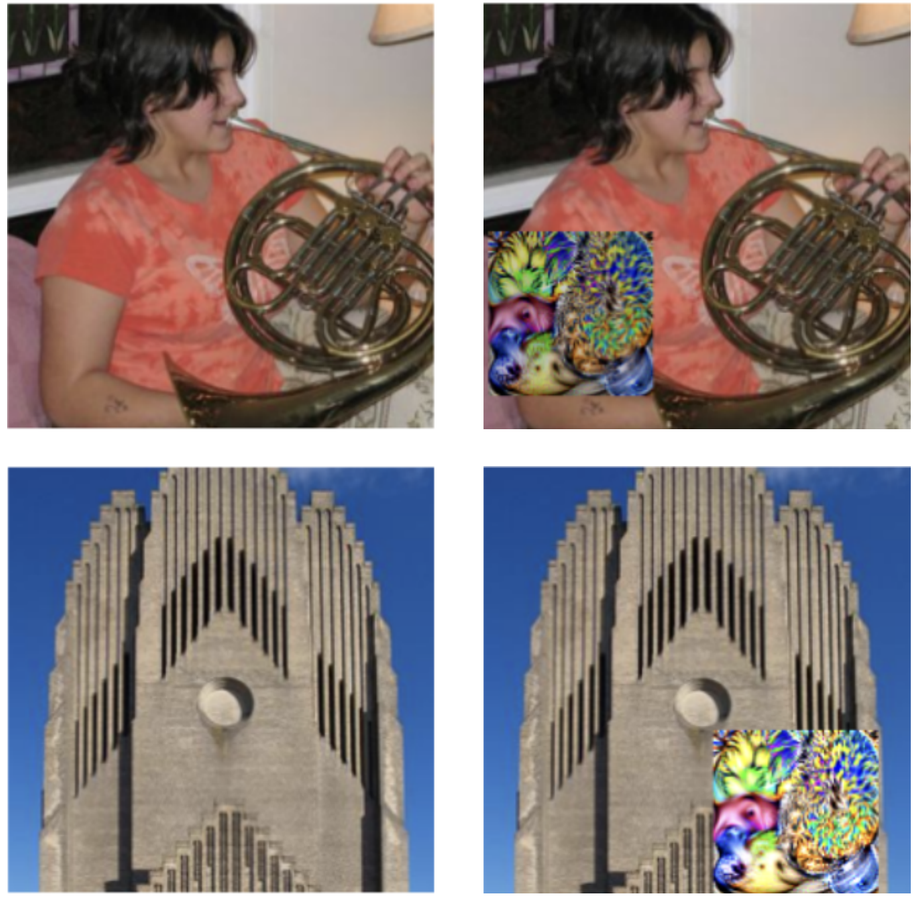
모델 A 검증 정확도

99.4%

11개 클래스 · 학습에 쓰지 않은 검증 사진 4,315장 · 바나나 390장은 모두 정답

06

Before / After: 기존 모델만 banana로 바뀌었다



	모델 A	모델 B	모델 C
프렌치 호른	99%	100%	100%
교회	85%	100%	100%

ResNet50

French horn 28%
→ **banana 86%**

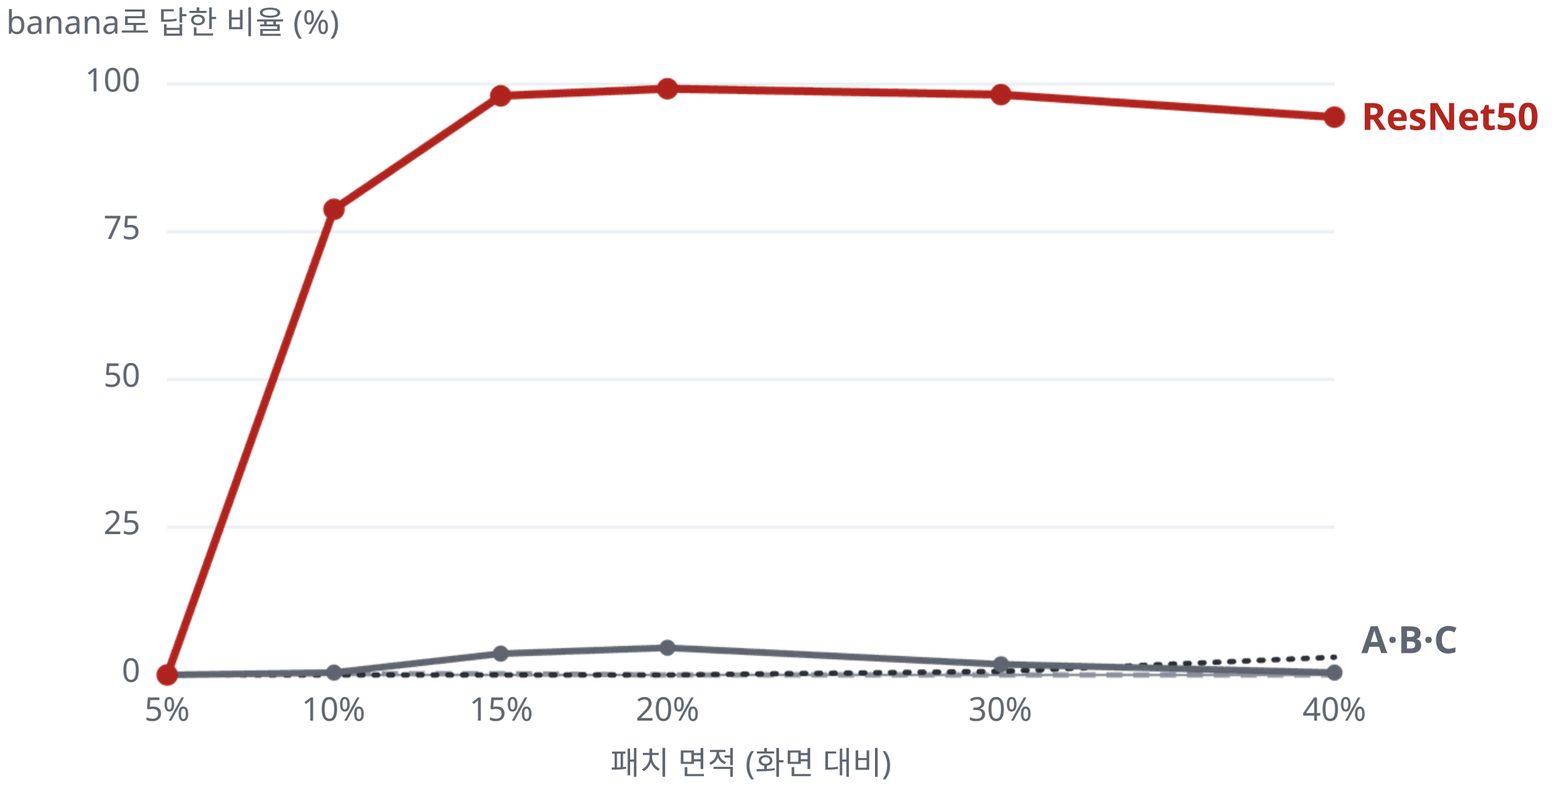
church 25%
→ **banana 86%**

A·B·C 칸: 정답 클래스의 확률(패치 전 → 후) · 모델은 1,000개 중에서 고르기 때문에 원래 확률이 낮다 · 예시 4장은 무작위로 뽑은 사진

07

면적별 결과

Imagenette 검증 사진 500장 · 패치를 회전 없이 면적만 바꿔 붙였을 때 banana로 답한 비율



기존모델 · 면적 15%

98.0%

20%의 면적일때 A모델

4.6%

패치 없음 · 노이즈 패치: 모든 모델 0%
(1,000장 평가)

08

결론

1

ResNet50 전용 무늬

패치는 기존 모델이 banana라고 답하게 만든 무늬일 뿐, 진짜 바나나의 특징이 아니다

2

몸통이 같아도 안 통한다

몸통이 ResNet50과 똑같은 A에서도 최대 4.6%. 새로 배운 fc는 패치를 바나나로 읽지 않았다

3

전이성은 약하다

구조가 다른 모델(0~5%)에 이어, 몸통은 같고 출력층만 다른 모델에서도 거의 통하지 않았다

바나나를 학습시켜서 이런 결과가 나온것 인지 아닌지 확인 할 수 있도록 바나나를 학습하지 않은 모델도 확인해 보는게 좋을 듯 함.